3/31 如何打造台版 Edge Impulse TinyML 開發平台

欧尼克斯實境互动工作室創辦人 許哲豪博士

- 邊緣智慧 v.s. 生成智慧

  △ 極小化(Edge AI / TinyML)：專注於邊緣端極少資源的環境

  - 硬体限制：使用MCU，儲存空間的運算力極其有限
  - 核心目標：智慧感測(聲音、影像、運动)，追求超小模型的超低功率。

  △ 極大化(Generative AI / Cloud AI)：依賴雲端無限資源

  - 硬体支持：以GPU为核心，處理超巨大資料集的模型
  - 核心目標：實現对話、影像生成的複雜程式撰寫

- AI 發展趨勢的核心技術

  △ 演進路徑：從感知AI轉向生成AI，再進一步發展到代理AI(Agentic AI)的最終的物理AI(Physical AI)

  △ 尺度擴展：關注從預訓練、後訓練到測試時尺度(Test-time Scaling)的長思考模式。

  △ 平台必備要素：

  - 半導体的計算能力(硬体底層)
  - 基礎模型的多模態技術(軟体算法)
  - 高整合性的開發工具(平台易用性)

- AI 技術演進：從神經網路到 Agentic AI：

△ 技術路徑：

- 從早期 CNN 和 RNN 演進至以 Transformer 為核心的大模型
- 多模態化，發展出 LLM、VLM、VLA

△ 應用升級：

從單一功能的 AI 代理進化到能團隊協作、整合功能的代理 AI

- 實作分級：台版開發平台的硬体選擇

針对不同算力需求（簡略系列）

1. 豪華版（本地運算）：使用 Mac Mini，具備強大算力和記憶体，適合完成本地化運行。
2. 主机版：使用 Intel NUC 或小型工業电腦，可搭配 Nvidia GPU
3. 嵌入式版（TinyML）：使用 ESP32-S3、LicheeRV-Nano 或 Pi5。這類 MCU/MPU 等級需依賴雲端 API 連結，是 TinyML 開發平台的重点。

- Nvidia 的角色：企業級 NemoClaw

△ 工具鏈：介紹 Nvidia NemoClaw 作为構建代理型 AI 的參考工具包

△ 關鍵思辨：

- 雲端 V.S. 本地：如何在边緣端實現 AI 代理？
- 資安議題：當 AI 轉向完全代理時，資料安全和隱私的权衡

- Edge AI 的廣泛定義和生態

△ 五大分類

- Edge Server：如 Nvidia.
- NB AI（AI PC）：Intel Core Ultra、AMD Ryzen 系列
- Mobile AI（SoC）：聯發科天璣 9300、高通 8 Gen3.
- SBC AI（單板电腦）：Pi5、Jetson AGX Orin、Keneron 等.
- Wearable AI（TinyML）：這是平台最底層，涉及 ARM Cortex-M 系列（M0-M85）和 Nuvoton、Himax 等台灣業者晶片

- Edge AI 如何定義

- 廣義定義：不上網就能完成所有 AI 推論
- 狹義定義：使用电池供电完成所有 AI 推論的獨立裝置

- 應用需求和算力对照

△ Wearable AI（MCU/TinyML）：智慧感測（喚醒詞、手勢、振动分析），單位为 MOPS

△ SBC AI（MPC/NPU）：电腦視覺（影像分類、物件偵測）和基礎自然語言處理，算力需 GOPS 到 1 TOPS

△ Edge Server/Mobile AI：生成式对話、繪圖及的模態應用，需求跳升至 10 ~ 100 TOPS ↑

- Edge AI 開發流程

  1. 資料收集與標註：基礎地基
  2. 模型建置與訓練調參：核心研發
  3. 模型優化：包含資料前處理與結果後處理
  4. 佈署測試：最後的落地驗證

- 加速運算晶片的分級與演進

  △ 晶片特性：從「通用/彈性」(CPU、GPU) 走向「專用/效能」(NPU、FPGA)

  △ MCU 等級核心晶片：
  - 涵蓋 CISC、RISC、RISC-V、DSP 及 NPU
  - 算力來源：提高時脈、平行/向量指令集、或異質加速

- 常見 MCU 之神經網路加速器 (NPU)

  △ ARM Ethos 系列：U55，U65，U85 (廣泛應用於 NXP、Renesas、AI 計算晶片)

  △ 其他供應商：ST (Neural-ART)、NXP (eIQ Neutron)、Renesas

  △ 重點指標：需注意算力單位 TOPS 的數值格式 (如 FP32/16、INT 16/8/4)，這直接影響模型的精度與執行效率

- 產業趨勢：從感知跨向生成式 AI

  △ 兩極化發展：雲端追求極大化 (GPU 算力、大模型)；邊緣端追求極小化 (MCU 運算、超低功耗

  △ 技術演進：AI 已從單一影像/聲音識別，進化到具備思考與執行能力的 AI Agent

- 硬体挑戰：克服四道牆

打造平台必須解決硬体加速的四大阻礙：

△ 算力牆与記憶体牆：解決運算与資料存取的不对稱

△ 能耗牆与通訊牆：迎緣設備最嚴苛的电力与傳輸限制

△ 硬体分級：涵蓋從豪華版（Mac Mini）到嵌入式版（ESP32／Pi 5）的跨平台支援

- 開發核心：量化框架与NPU

△ 主流工具：必須整合 LiteRT（原TF Lite）与 ExecuTorch（PyTorch）兩大生態

△ 加速關鍵：善用 NPU（如 ARM Ethos）進行矩陣運算加速，落實資料收集、模型優化到佈署的五大流程。

- TinyML 產業大併購：高通（Qualcomm）時代開始

2025年 TinyML 領域發生大規模收購，Qualcomm 先後併購了 Edge Impulse 与 Arduino，正式統合了雲端訓練、嵌入式開發平台、硬体載具的完整生態

- 次時代硬体載具：Arduino UNO Q / Ventuno Q
  - Arduino UNO Q (2025)：搭載高通 Dragonwing QRB2210，具備 Cortex-A53(2GHz) 和 Adreno 702 GPU，並整合 STM32M33 異質核心
  - Arduino Ventuno Q (2026)：算力大幅提升，搭載 IQ8275，具備 40TOPS NPU，支援多模態 AI 應用
- Edge Impulse 主要功能－資料集建置
  - 多管道資料匯入：
  - 時序信号處理
  - 影像標註自动化
  - 物件偵測

Edge Impulse

從裝置

- 手机掃描 QR code 建立裝置連結，可傳送聲音、運动及影像感測資料
- edge-impulse-data-forward 開發板透过 COM 埠直送文字串資料適合連續、低速(2～400 Hz)感測器
- edge-impulse-daemon 開發板直送訊号 (限Edge Impulse開發板) 利用电腦上裝置直接將聲音、運动及影像感測資料上傳到雲端

從檔案

可將 CBOR, JSON, CSV, WAV, JPG, PNG, AVI, MP4 等格式檔案(夾)直接上傳作为資料集

- Edge Impulse 主要功能 — 模型訓練

訓練超參數
- 訓練次數
- 優化器
- 學習率
- 批次大小
- 模型結構

訓練結果
- 推論精度 / 損失率
- 混淆矩陣
- 資料分佈
- FLASH / SRAM 使用量
- 推論預估時間

- Edge Impulse 主要功能 — EON 模型優化

- Flash 優先
- SRAM 優先
- 推論精度優先
- 推論速度（延遲）優先

- 如何打造台版 Edge Impulse

为何要有？
- △ 提升嵌入式人工智慧工程韌性
- △ 加速 Edge AI & TinyML 開發效率
- △ 提供國內產官學研整合性實驗平台
- △ 共享資源快速提升工程水準
- △ 高度整合國內晶片和軟件業者

功能配置？
- △ 雲端及本机端相似開發模式
- △ 資料資建工具
- △ 模型訓練 / 調參工具
- △ 模型優化 / 部署工具
- △ ML Ops 管理

- TinyML 雲端開發平台 — SenseCraft AI

支援 Grove Vision AI Kit V2 / SenseCAP A1101 / SenseCAP Watcher (Himax WE2)、Xiao ESP32S3、Nvidia Jetson、reCamera

主要以視覺為主，影像分類，物件偵測，其它應用要離線工程模式開發。

提供資料建置、模型訓練、共享模型、快速部署等服務

- Edge AI 雲端開發平台 — Roboflow

主要為影像類應用雲端標註工具
具有巨量公開資料及模型
可支援簡單模型訓練
支援多種硬体部署 (x86, Nvidia Jetson / GPU/TRT, Arm, CAK, Pi)

- 新唐 NuML Toolkit / Nu Edge Wise

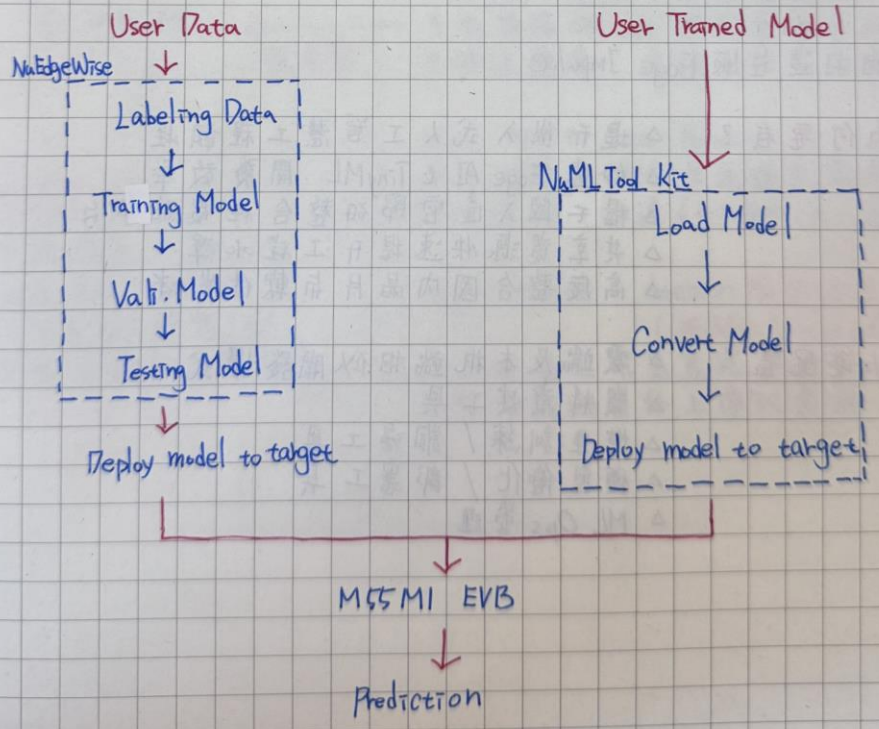

- 自建平台技術痛点

△ 模型轉換（硬体加速） 算子相容性、
NPU 轉譯工具……

△ 模型压縮（優化） 量化、剪枝、蒸餾、权重共享…

△ 自动產生模型（AutoML） Neural Network Search (NAS)
自动產生最優模型結構

△ 訓練加速 配合高速 GPU 或使用遷移學習