具冒充者與欺騙攻擊偵測之語者辨識

演講者: 雲林科技大學 資訊工程系 許正欣 副教授 演講日期: 2026 / 04/ 30

- **摘要（Extended Abstract）**

本報告整理語者辨識與欺騙攻擊偵測系統的相關內容，說明語音身分驗證從特徵擷取、模型訓練、分數判斷到系統整合的主要流程。語者辨識可分為本文相關與本文無關兩類，前者要求使用者朗讀指定語句，辨識條件較受控制；後者則不限制語句內容，因此更接近真實應用場景，但也更容易受到錄音重放、語音合成與聲音轉換等欺騙攻擊影響。系統可透過 CQCC、MFCC 與 i-vector 等特徵描述語音訊號，再利用 SVM 或 DNN 分類器判斷語音是否為真實語音，並進一步結合語者辨識模型確認是否為目標語者。整體而言，CQCC 搭配 Single-model DNN 在欺騙攻擊偵測上具有較佳表現，能在維持目標語者通過率的同時降低偽造語音通過率；此外，分數正規化、條件式重試與整體學習也可作為平衡安全性與可用性的補充機制。

- **前言（Introduction）**

隨著語音助理、智慧門禁、行動銀行與各類物聯網裝置的普及，語音已不只是人機互動的輸入方式，也逐漸成為身分驗證的重要依據。語者辨識的主要目的，是根據一段語音判斷說話者是否為系統中已註冊的使用者。相較於密碼或指紋等方式，語音驗證具有非接觸、操作自然，以及硬體需求較低等優點，因此被廣泛應用在不同情境中。然而，語音本身也容易被錄製、複製，甚至透過語音合成或聲音轉換技術偽造。如果系統只依賴傳統的語者辨識模型，而沒有搭配偽造語音偵測機制，便可能在面對重放攻擊、語音合成或聲音轉換攻擊時產生安全風險。

語者辨識一般可分為本文相關（text-dependent）與本文無關（text-independent）兩種類型。本文相關的語者辨識會要求使用者朗讀指定內容，由於語句固定，系統較容易比較聲學特徵與語者特徵，因此通常能得到較穩定的辨識結果。相對地，本文無關的語者辨識不限制說話內容，系統必須從任意語音中擷取能代表說話者身分的特徵，因此對模型的泛化能力要求較高。這樣的分類也對應到不同應用場景：若是固定通關口令或簡短驗證句，本文相關方式較為適合；若是自然對話中的持續身分驗證，本文無關方式則具有更高的彈性。

從系統安全的角度來看，語者辨識不應只判斷「這段語音像不像某位使用者」，也需要進一步確認「這段語音是否真的由真人即時發出」。ASVspoof 2019 資料庫便是針對這類問題所建立的重要資料集，涵蓋邏輯存取與實體存取兩種情境，並收錄語音合成、聲音轉換與重放攻擊等不同類型的偽造語音。相關研究指出，ASVspoof 2019 將多種攻擊方式納入同一評估架構，有助於比較不同反欺騙模型在語音驗證安全性上的表現[1]。因此，本報告將從兩個層面進行討論：首先說明語音特徵與分類模型如何用來表示語者身分或攻擊型態，其次探討反欺騙模型如何與語者辨識模型結合，形成較完整且安全的語音驗證流程。

- **語音特徵擷取與模型基礎**

語音訊號本身是連續時間波形，直接輸入分類器往往會受到音量、語速、通道與背景噪音影響，因此語者辨識與反欺騙系統通常會先進行特徵擷取。投影片中整理的特徵包含 MFCC、CQCC 與 i-vector。MFCC 是語音處理中最常見的短時頻譜特徵之一，透過模擬人耳對頻率的非線性感知，將語音分幀、加窗、轉換至頻域，再經由濾波器組與倒頻譜轉換得到低維特徵。它能有效描述聲道共振峰與語音音色，因此在傳統語者辨識中被大量使用。不過，MFCC 對於語音合成或重放攻擊中某些細微頻譜差異可能不夠敏感，因此在反欺騙任務中常需要與其他特徵互補。

CQCC 是本次投影片中特別強調的反欺騙特徵。它的基礎是常數 Q 轉換，也就是依照頻率調整分析視窗，使低頻區域具有較高頻率解析度，高頻區域則具有較高時間解析度。這種配置不同於傳統傅立葉轉換的線性頻率間隔，較接近音樂與語音中對數尺度的頻率分布。Todisco 等人提出 CQCC 作為自動語者驗證的 spoofing countermeasure **[2]**，指出常數 Q 轉換結合倒頻譜處理能有效捕捉偽造語音與真實語音之間的頻譜差異。課堂投影片中的架構也採用 CQCC 作為主要特徵，並在後續實驗中顯示它比 MFCC 與 i-vector 更適合欺騙攻擊偵測。

i-vector 則代表另一種語者建模觀點。傳統 GMM-UBM 方法會先利用大量背景語料訓練 Universal Background Model，再透過適應機制建立特定語者模型。Reynolds 等人的 GMM-UBM 架構**[3]**奠定了長期以來語者驗證的基礎，系統以 likelihood ratio test 判斷輸入語音較像目標語者或背景語者。後續 i-vector 方法將高維的語者 supervector 壓縮到低維 total variability space，其基本形式可寫為 $M = m + T w$，其中 M 是語者 supervector，m 是 UBM supervector，T 是 total variability matrix，w 則是低維的 i-vector。 Dehak 等人指出，i-vector 以低維向量同時表徵語者與通道變異，使後端分類器能以較有效率的方式進行比對**[4]**。

由於不同特徵對語音訊號的敏感度不同，投影片中的系統並未只依賴單一處理流程，而是將特徵擷取、維度轉換與分類器設計視為可調整的模組。在欺騙攻擊偵測模型中，輸入特徵會經由分類器判斷為 Real 或 Spoofing；在語者辨識模型中，特徵則被用來判斷輸入語音是否來自目標語者。這種模組化架構的優點是可以分別優化反欺騙與語者驗證兩項任務，再透過系統層的決策策略整合兩者。

- **欺騙攻擊偵測與與者辨識流程**

系統架構可分為兩個主要階段，呈現出先確認語音真偽、再確認說話者身分的安全設計。第一階段是欺騙攻擊偵測模型，目標是過濾由語音合成、聲音轉換或錄音重放所產生的假語音；第二階段則是語者辨識模型，用來判斷通過第一階段檢測的語音是否屬於目標使用者。透過這種兩階段流程，可以降低偽造語音直接進入語者辨識模型而造成誤判的風險。即使攻擊者提交的合成語音或轉換語音在音色上接近目標語者，反欺騙模型仍可根據頻譜細節與聲學特徵判斷其是否為真實人聲，並在前端阻擋可疑語音。

在分類器方面，常見方法包括 Linear SVM、RBF-SVM 與 Single-model DNN。SVM 的基本概念是尋找能夠分隔不同類別的最大間隔超平面；當資料在原始特

徵空間中不容易線性分離時，RBF kernel 可將資料映射到更高維的特徵空間，以提升分類能力。Cortes 與 Vapnik 所提出的支援向量網路[5]，至今仍常被用作小型或中型特徵分類任務的基準模型。相較之下，DNN 透過多層非線性轉換學習特徵之間的複雜關係，因此在樣本量足夠的情況下，通常能比傳統分類器捕捉更細緻的語音差異。整體而言，Single-model DNN 搭配 CQCC 特徵時，在準確率與偽陽率表現上通常具有較佳效果。

除了分類器本身，決策門檻也是影響系統安全性的重要因素。對欺騙攻擊偵測模型而言，若模型分數低於門檻值，通常會判定為生成語音或可疑語音；若高於門檻值，則判定為真實語音。對語者辨識模型而言，若分數低於門檻值，通常會被判定為偽冒者；若分數高於門檻值，則判定為目標語者。門檻設定的困難在於，它會同時影響兩種錯誤情況：若門檻設得過嚴，真實使用者可能被拒絕，造成 false rejection；若門檻設得過寬，偽冒者或偽造語音可能通過，造成安全風險。因此，實務上必須依照應用場景的風險等級調整門檻。例如銀行交易或高安全性門禁系統會傾向降低偽接受率，而一般語音助理則可能更重視使用上的便利性。

此外，分數正規化、條件式重試與整體學習也可作為提升系統穩定性的輔助方法。分數正規化的目的，是在不同語者、不同語料或不同錄音條件下調整模型輸出分數，使目標語者與冒充者的分數分布更容易透過同一門檻進行切分。不過，正規化方法不一定能同時提高目標語者接受率與冒充者拒絕率，因為兩者的分數分布往往會有部分重疊。條件式重試則是針對可能被誤拒的真實使用者提供再次驗證機會，但若重試次數設定過高，也可能讓攻擊者獲得更多嘗試機會。整體學習則透過多個分類器共同決策，降低單一模型誤判造成的影響，特別是在面對不同語料庫或不同攻擊型態時，有助於提升系統的穩定性與泛化能力。

- **實驗結果與系統整合討論**

欺騙攻擊偵測系統主要以 CQCC 維度與 frame size 作為輸入設定，其中輸入層大小為 $60 \times 150 = 9000$。這裡的 60 代表 CQCC 特徵維度，150 則代表 1 秒內切分出的 frame 數。模型輸出的是語音被判定為真實語音的機率，訓練時使用 Adam optimizer，學習率設定為 0.001，並採用 binary cross-entropy 作為 loss function。由此可知，模型的任務屬於二元分類，也就是將輸入語音分為 real 與 spoofing 兩類。當輸入維度為 9000 且隱藏層規模較小時，real 通過率約為 97.5%，spoofing 通過率約為 10.3%；當模型規模擴大後，real 通過率仍維持在 97% 左右，但 spoofing 通過率上升到約 12.6%。這表示模型容量增加並不一定能有效降低偽造語音通過率，反而可能帶來過度適應或門檻校準上的問題。

在降維實驗中，可進一步比較原始 9000 維特徵與 LDA、PCA 不同維度設定下的表現。原始特徵的 real 通過率為 96.6%，spoofing 通過率為 14.3%；LDA 降到 1 維後，real 通過率下降到 87.2%，spoofing 通過率為 16.6%。若使用 PCA 降到 4500、900、450 與 90 維，real 通過率分別約為 87.2%、89.2%、90.6% 與 92.7%，spoofing 通過率則約為 15.7%、17.4%、18.0% 與 19.6%。這些結果顯示，降維雖然可以降低模型複雜度與儲存成本，但若壓縮過度，可能會移除對真偽辨識有幫助的語音細節，使真實語音與偽造語音更難區分。對嵌入式系統部署而言，

降維確實能減少運算負擔，但仍必須在模型大小、真實語音通過率與偽造語音阻擋率之間取得平衡。

在模型與特徵比較方面，若先固定語音特徵為 CQCC，並比較 Linear-SVM、RBF-SVM 與 Single-model DNN，可以看出不同分類器對結果有明顯影響。Linear-SVM 的準確率為 83.3%，偽陽率為 18.4%，真陽率為 85.1%；RBF-SVM 的準確率提升到 90.0%，偽陽率為 16.5%，真陽率為 97.0%；Single-model DNN 的準確率則達到 91.6%，偽陽率降至 10.8%，真陽率為 94.2%。若固定分類器為 Single-DNN，再比較 MFCC、i-vector 與 CQCC，結果顯示 MFCC 的準確率為 71.0%，i-vector 為 75.3%，CQCC 則達到 91.6%。在偽陽率方面，CQCC 的 10.8% 也低於 MFCC 的 19.0% 與 i-vector 的 16.1%。因此，CQCC 在此實驗中展現出較佳的欺騙攻擊偵測能力，尤其能更有效降低偽造語音被誤判為真實語音的機率。

靜音移除實驗則提供了另一個值得注意的觀察。由於 ASVspoof 資料集中並沒有明確標示哪些靜音段應該被移除，因此可比較保留靜音與移除靜音兩種設定下的差異。結果顯示，保留靜音時，模型準確率為 91.6%，偽陽率為 10.8%，真陽率為 94.2%；移除靜音後，準確率下降為 86.8%，偽陽率約為 10.7%，真陽率則降為 83.8%。這表示靜音段不一定只是無用資訊，其中可能包含錄音環境、合成拼接痕跡或重放設備所留下的線索。若在沒有充分分析的情況下直接移除靜音，反而可能破壞模型判斷偽造語音時所依賴的資訊。

進一步來看，欺騙攻擊偵測模型也可以與語者辨識模型進行整合。整合流程中，系統會先透過欺騙攻擊偵測模型判斷輸入語音是否可信，再將通過檢測的語音交給語者辨識模型，判斷其是否屬於目標語者。當語者辨識端採用全數決整體學習時，整合系統在 ASVspoof2019 與不同語料庫上的冒充者阻擋率大多能維持在較高水準。例如 ASVspoof2019 的整合系統數值約為 92.5%，語料庫 A、B、C 也多接近 100%。這說明前端反欺騙模型與後端語者辨識模型的結合，比單一模型更符合實際安全需求，因為它同時處理了「語音是否真實」與「說話者是否正確」兩個問題。

最後，若將系統部署在 Nvidia Jetson TX2 等嵌入式平台上，除了模型準確率之外，也必須考量記憶體、功耗與即時性限制。因此，模型大小、特徵維度與推論時間都會影響實際應用的可行性。從前述降維實驗可以看出，單純壓縮特徵維度未必能維持良好的安全性，因此較合理的方向，是在保留關鍵語音特徵的同時，搭配模型壓縮、量化或輕量化網路設計。此外，也可以進一步嘗試 recurrent neural network 等能處理序列資料的模型，以改善輸入長度不一致的問題，並更完整地利用語音訊號中的時間依賴資訊。

- **結論**

綜合上述內容與相關文獻可知，語者辨識系統若要應用於安全驗證場景，不能只停留在傳統的「辨識語者」層面，而必須進一步擴展為「同時確認語音真偽與語者身分」。MFCC、i-vector 與 GMM-UBM 等方法過去在語者辨識上具有重

要貢獻，但在面對語音合成、聲音轉換與錄音重放等攻擊時，單靠語者辨識模型已不足以確保系統安全。因此，前端反欺騙機制成為語音身分驗證中不可或缺的一環。CQCC 透過常數 Q 轉換擷取語音特徵，能更有效描述偽造語音在頻譜上的細微差異；搭配 Single-model DNN 後，也能在欺騙攻擊偵測上取得較佳的整體表現，因此可視為本系統中的主要技術核心之一。

實驗結果也顯示，模型效能不能只用準確率單一指標來衡量。對語音安全系統而言，偽造語音通過率、偽陽率、真陽率、目標語者接受率與冒充者阻擋率都代表不同層面的意義。若過度降維，雖然能降低運算量與儲存成本，卻可能犧牲反欺騙能力；若直接移除靜音段，也可能刪除錄音環境、合成痕跡或重放設備所留下的有用線索。此外，分數正規化、條件式重試與整體學習雖然有助於提升系統穩定性，但仍需要配合門檻設定與實際風險情境進行調整。換言之，一個完善的語者辨識安全系統，不只是追求單一模型的高準確率，而是必須在安全性、便利性與部署成本之間取得合理且可解釋的平衡。

未來若要進一步延伸此研究，可從三個方向著手。第一，可導入能處理長短不一語音序列的模型，例如 RNN、LSTM 或 Transformer，使系統能更充分利用語音中的時間上下文資訊。第二，可針對嵌入式平台進行模型壓縮、量化與即時推論最佳化，讓系統能在 Jetson TX2 或其他邊緣裝置上穩定運行。第三，可建立更完整的跨資料庫評估機制，使模型不只在特定資料集上表現良好，也能在未知語者、未知錄音環境與未知攻擊技術下維持可靠度。透過這些方向，語者辨識與欺騙攻擊偵測系統才能更接近實際可部署的安全應用。

參考文獻

[1] X. Wang et al., “ASVspoof 2019: A large-scale public database of synthesized, converted and replayed speech,” Computer Speech & Language, vol. 64, Art. no. 101114, 2020.

[2] M. Todisco, H. Delgado, and N. Evans, “Constant Q cepstral coefficients: A spoofing countermeasure for automatic speaker verification,” Computer Speech & Language, vol. 45, pp. 516–535, 2017.

[3] D. A. Reynolds, T. F. Quatieri, and R. B. Dunn, “Speaker verification using adapted Gaussian mixture models,” Digital Signal Processing, vol. 10, no. 1–3, pp. 19–41, 2000.

[4] N. Dehak, P. J. Kenny, R. Dehak, P. Dumouchel, and P. Ouellet, “Front-end factor analysis for speaker verification,” IEEE Transactions on Audio, Speech, and Language Processing, vol. 19, no. 4, pp. 788–798, 2011.

[5] C. Cortes and V. Vapnik, “Support-vector networks,” Machine Learning, vol. 20, pp. 273–297, 1995.