# 口罩檢驗管理系統之研究報告
# Mask Inspection Management Systems

演講者: 國立台中科技大學 資訊工程系 陳永隆 教授兼院長
演講日期: 2026 / 03/ 10

## 1. 摘要（Extended Abstract）

隨著智慧製造與自動化技術的快速發展，產品品質檢測逐漸由人工檢測轉向自動化視覺檢測系統。傳統人工檢測方式容易受到人為疲勞與主觀判斷影響，導致檢測效率降低及錯誤率增加，因此利用電腦視覺與深度學習技術進行自動化品質檢測已成為現代製造業的重要研究方向。近年來，深度學習模型特別是卷積神經網路（CNN）在影像辨識與缺陷檢測領域展現出良好的效能，使得自動光學檢測（Automatic Optical Inspection, AOI）系統能夠有效提升產品品質控制能力[1]。此外，在口罩製造產線中，由於口罩需求量增加與產品品質要求提高，如何快速且準確地偵測口罩缺陷成為重要議題。相關研究指出，透過深度學習結合影像前處理技術，可以有效提升口罩缺陷檢測的準確率並降低人工檢測成本[2]。

本研究提出一套口罩檢驗管理系統，利用影像前處理技術結合深度學習模型進行口罩缺陷辨識。研究中採用三種不同的深度學習架構，包括 ResNet152V2、InceptionV3 以及 Xception，並透過實驗比較各模型在口罩影像分類任務中的表現。實驗結果顯示，在加入影像前處理後，各模型的辨識準確率皆有明顯提升，其中 Xception 模型表現最佳。研究成果顯示，透過深度學習與影像處理技術整合，可以有效建立高效率的口罩檢測系統，並可應用於智慧製造與品質管理領域。

## 2. 前言（Introduction）

在現代製造產業中，產品品質檢測是確保產品可靠度與安全性的重要流程。傳統的品質檢測方式多依賴人工目視檢測，但此方法不僅需要大量人力，也容易因長時間工作而產生疲勞，進而影響判斷的準確性。因此，如何利用自動化檢測技術提升品質檢測效率，成為智慧製造與工業自動化的重要研究議題。研究指出，隨著深度學習與高效能運算設備的發展，自動光學檢測系統已逐漸取代傳統人工檢測，並能在製造過程中即時監控產品品質[3]。

在影像辨識領域中，卷積神經網路（Convolutional Neural Network, CNN）被廣泛應用於影像分類與物件辨識任務。CNN 能夠自動從影像中學習特徵並建立分類模型，相較於傳統影像處理方法需要手動設計特徵的方式，CNN 具有更高的準確率與更強的泛化能力[4]。因此，CNN 已成為現代電腦視覺與工業檢測系統中最重要的核心技術之一。當應用於口罩製造產業中，口罩品質檢測同樣是一項重要課題。由於口罩在製造過程中可能產生不同類型的缺陷，例如破損、污染或結構異常等，因此需要透過檢測系統將不良品從產線中移除，以確保產品品質與使用安全。然而，人工檢測方式不僅效率較低，也難以維持穩定的檢測品質。相關研究指出，透過深度學習結合影像處理技術，可以有效建立自動化口罩缺陷檢測系統，並提升生產線品質管理效率[5]。

基於上述背景，本研究提出一套口罩檢驗管理系統，透過影像前處理技術與深度學習模型進行口罩影像辨識與分類。本研究主要比較 ResNet152V2、InceptionV3 與 Xception 三種深度學習模型在口罩缺陷辨識任務中的表現，並分析影像前處理技術對模型效能的影響。研究成果可作為未來智慧製造與自動化品質檢測系統的重要參考。

## 3. 研究方法 (Proposed Method)

本研究提出三種主要方法，分別結合不同深度學習架構與影像前處理技術，進行口罩影像分類與辨識。研究中所採用的三種模型為 ResNet152V2、InceptionV3 以及 Xception，並搭配影像前處理（Image Preprocessing）技術以提升辨識效果。

首先，在影像前處理階段，系統會先將輸入影像進行裁切、調整大小以及資料增強等處理，使資料更適合模型訓練。影像處理完成後，會將資料輸入至深度學習模型進行特徵萃取與分類。在第一種方法中，研究使用 IP-ResNet152V2 架構，將影像前處理技術與 ResNet152V2 深度殘差網路結合。ResNet 系列模型透過殘差學習（Residual Learning）解決深層網路訓練時的梯度消失問題，使模型可以建立更深的神經網路結構並提升辨識能力。第二種方法採用 IP-InceptionV3 架構。InceptionV3 模型透過多尺度卷積運算，能夠在同一層中同時提取不同尺寸的影像特徵，因此在影像分類任務中具有良好的表現。透過影像前處理後再輸入 InceptionV3，可以有效提升模型在口罩影像辨識上的準確率。第三種方法則是 IP-Xception 架構。Xception 模型是以深度可分離卷積（Depthwise Separable Convolution）為核心設計，透過將空間特徵與通道特徵分離處理，能在降低計算量的同時維持良好的辨識效果，因此在影像辨識任務中被廣泛應用。

在模型訓練方面，本研究設定不同訓練回合數（Epoch），例如 15 回合、30 回合以及 60 回合，以觀察模型在不同訓練階段下的準確率與損失值變化。此外，研究也透過混淆矩陣（Confusion Matrix）來分析模型對各類口罩缺陷的分類能力。

### 3.1 系統流程

研究所提出的目標偵測系統主要包含影像資料輸入、影像前處理、特徵提取以及目標偵測與分類等階段。系統首先接收遙測影像資料，這些影像可能來自衛星或無人機拍攝，通常具有高解析度與複雜背景。在影像輸入後，系統會進行影像前處理，以確保資料的一致性與品質。此階段主要包含影像尺寸調整、資料標註整理以及資料增強等操作。資料增強方法如影像旋轉、縮放與亮度調整，可有效增加資料多樣性並提升模型泛化能力[6]。完成前處理後，影像資料會輸入至深度神經網路進行特徵提取。透過卷積神經網路，模型可以自動學習影像中的邊緣資訊、紋理特徵以及物體形狀等關鍵資訊。最後，系統會進行目標偵測與分類，並輸出影像中各物體的位置與類別。

### 3.2 IP-ResNet152V2 方法

ResNet（Residual Network）是一種深層卷積神經網路架構，其主要特色為殘

差連接（Residual Connection）。此結構能夠在深層網路中保留前一層的特徵資訊，有效解決梯度消失問題，使模型能夠訓練更深層的網路結構[7]。在本研究中，ResNet152V2 被用作影像特徵提取模型。該模型具有較深的網路層數，因此能夠學習更複雜的影像特徵。當影像輸入模型後，卷積層會逐步提取不同層級的特徵資訊，從低層的邊緣與紋理特徵，到高層的語意特徵。透過深層殘差結構，ResNet152V2 能夠在維持模型穩定訓練的同時提升影像辨識能力。因此，在本研究的實驗比較中，此架構被用來評估深層特徵提取對目標偵測效能的影響。

### 3.3 IP-InceptionV3 方法

InceptionV3 是一種多尺度卷積神經網路架構，其主要特色在於 Inception 模組。該模組透過多種不同大小的卷積濾波器，同時分析影像中的不同尺度特徵，使模型能夠同時捕捉局部細節與整體結構資訊[8]。在遙測影像中，物體大小通常差異較大，例如車輛、建築物或道路等目標在影像中的尺度可能不同。因此，多尺度特徵提取對於提升模型辨識能力具有重要作用。本研究利用 InceptionV3 作為特徵提取模型，使系統能夠在不同尺度下學習影像特徵。透過多尺度卷積結構，模型可以同時分析不同尺寸的物體特徵，進而提升目標偵測的準確率。

### 3.4 IP-Xception 方法

Xception（Extreme Inception）是一種基於深度可分離卷積（Depthwise Separable Convolution）的卷積神經網路架構。此方法將傳統卷積運算拆分為深度卷積與逐點卷積兩個步驟，以降低模型運算成本並減少參數數量 [9]。相較於傳統卷積神經網路，深度可分離卷積能夠有效降低計算量，同時保持良好的特徵學習能力。因此，Xception 在許多影像分類與辨識任務中展現出良好性能。

在本研究中，Xception 模型被用作另一種特徵提取架構，以比較其在遙測影像目標偵測任務中的表現。透過此方法，可以分析不同 CNN 架構在模型準確率與計算效率上的差異。

## 4. 實驗環境與設定 (Experimental Setup)

本研究使用深度學習模型進行訓練與測試，實驗環境包含高效能運算設備與 GPU 加速。實驗系統主要使用 NVIDIA GPU 進行模型訓練，以提升深度神經網路運算效率。在模型訓練過程中，本研究設定不同訓練回合數（Epoch）以觀察模型效能變化。訓練過程中採用 categorical cross-entropy 作為損失函數，並設定適當學習率以確保模型穩定收斂。此外，本研究亦透過資料增強技術增加訓練資料多樣性，例如影像旋轉與縮放等方式。相關研究指出，資料增強可以有效提升深度學習模型的泛化能力並降低過擬合問題。

## 5. 實驗結果與分析 (Experimental Results)

本研究針對三種不同的 CNN 架構進行實驗比較，以評估其在遙測影像目標偵測任務中的表現差異。實驗過程中分別設定不同的訓練回合數（Epoch），並觀

察模型在訓練過程中的準確率（Accuracy）與損失函數（Loss）變化情形，以了解模型學習的收斂情況與整體效能。而從實驗結果可見，隨訓練回合數增加，各模型的準確率皆有逐漸上升的趨勢，而損失函數則持續下降，這表示了模型能有效學習影像中的特徵資訊。特別是於訓練後期，準確率的提升幅度逐漸趨於穩定，表示模型已開始收斂並能穩定地進行目標辨識。這結果也反映出了深度學習模型在充分訓練後，能夠建立較為完整的影像特徵。

除此之外，在三種模型架構的比較中，ResNet152V2 在整體辨識準確率方面表現較為好。由於 ResNet 架構是透過殘差連接（Residual Connection）改善深層神經網路的訓練問題，使模型能夠學習更深層並更具代表性的影像特徵，因此在複雜場景的辨識任務中通常能取得較佳效果。此外，較深的網路層數也有助於提升模型對於影像細節的理解能力，使其在遙測影像中多樣化的目標辨識任務中展現較高的準確率。

相較來說，InceptionV3 在多尺度特徵分析方面具有一定優勢。其多分支卷積結構能同時處理不同大小的卷積核，因此對於尺寸差異較大的物體具有良好的辨識能力。而 Xception 架構則是透過深度可分離卷積降低模型計算複雜度，使模型在保持良好辨識能力的同時，也能提升運算效率。雖然這兩種模型在整體準確率上略低於 ResNet 架構，但在計算效率與模型複雜度方面仍具有一定優勢。為了進一步分析模型的分類能力，本研究亦利用混淆矩陣（Confusion Matrix）觀察各類別之間的辨識情形。從分析結果可以發現，大部分類別皆能被模型正確辨識，僅在少數類別之間出現輕微誤判。這些誤判通常發生於外觀特徵較為相似的物體類別，例如形狀或顏色相近的目標。整體而言，各模型在多數類別上均能維持良好的辨識能力。

綜合上述結果，不同 CNN 架構在目標偵測任務中各有其優勢。ResNet152V2 在整體辨識準確率方面表現最佳，而 InceptionV3 與 Xception 則在多尺度特徵學習與計算效率方面具有一定優勢。透過這些模型與 YOLOv8 架構的結合，本研究所提出的方法能有效提升遙測影像目標偵測的整體效能。

## 6. 結論

本研究建置了一套以深度學習為核心的口罩檢驗管理系統，並透過影像前處理技術搭配卷積神經網路模型，建立自動化的口罩缺陷辨識流程。在研究過程中，選用了 ResNet152V2、InceptionV3 以及 Xception 三種常見的深度學習架構作為主要模型，並透過實驗方式比較不同模型在口罩影像分類任務中的辨識能力與整體效能。實驗結果顯示，在加入適當的影像前處理後，模型在影像特徵擷取與分類判斷上的表現皆有所提升，整體辨識準確率也呈現明顯改善。

在模型效能的比較方面，三種深度學習架構皆能達到一定程度的辨識效果，但在實際表現上仍存在差異。其中，Xception 模型在本研究的實驗中展現出較佳的分類能力，其辨識準確率相對較高；InceptionV3 的表現則次之，而 ResNet152V2 在整體辨識穩定度方面亦維持良好的表現。此外，從模型訓練過程的結果可以觀察到，隨著訓練回合數的增加，模型的準確率逐漸提升，而損失值

則呈現下降的趨勢。這代表模型在訓練過程中逐步學習到影像中的重要特徵，並能夠建立有效的分類能力。

整體而言，本研究結果顯示，將影像前處理技術與深度學習模型結合，可以建立一套具有良好辨識能力的口罩檢測系統。相較於傳統人工檢測方式，此系統能有效降低人為判斷造成的誤差，同時也能提升檢測效率與穩定度，對於製造產線中的品質管理具有一定的實務應用價值。未來研究可進一步擴充資料集規模，以提升模型在不同環境與樣本條件下的泛化能力。此外，也可以嘗試導入其他深度學習架構或即時影像辨識技術，使系統更適合應用於實際生產環境。若能進一步整合即時監控與生產管理系統，將有助於建立更完整的智慧製造品質管理機制。

**參考文獻**


[1] Tulbure, A., et al. “Deep CNN-based visual defect detection: Survey of current literature.” *Computer Vision and Image Understanding*, 2023.

[2] Woo, J., & Lee, H. “Nonlinear and Dotted Defect Detection with CNN for Multi-Vision-Based Mask Inspection.” *Sensors*, 2022.

[3] Guo, L., et al. “Improvement of Mask R-CNN and deep learning for defect detection and segmentation in electronic products.” *PLOS ONE*, 2025.

[4] LeCun, Y., Bengio, Y., & Hinton, G. “Deep Learning.” Nature, 2015.

[5] Ho, T. “Mask Defect Detection: A Journey through Real-World Applications of CNN-based Models.” *AIMLR*, 2023.

[6] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Proc. Advances in Neural Information Processing Systems (NIPS)*, 2012, pp. 1097–1105.

[7] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[8] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, “Rethinking the Inception architecture for computer vision,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 2818–2826.

[9] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1251–1258.